

第3章 基于 EKF-LSTM 无人机轨迹预测算法

在无人机轨迹欺骗中,无人机轨迹预测作为轨迹欺骗的前期部分有着重要作用,轨迹预测的精确性直接决定了后期欺骗效果的好坏。无人机轨迹预测无论是二维路径,还是三维路径,都是非线性的时间序列问题,预测估计点不宜出现跳变太大的情况,且在预测过程中需要减少预测模型训练时间,提高模型的预测精度达到理想的预测效果。结合上述问题,本章提出了 EKF-LSTM 的融合算法进行无人机轨迹预测。在轨迹预测时,因雷达探测目标无人机运动信息存在噪声干扰,不能进行准确预测。首先分析无人机运动模型并将雷达探测无人机的观测数据作为输入,运用扩展卡尔曼滤波算法进行预测,得到对目标无人机初步的预测效果。接着为进一步降低预测误差,运用长短期记忆神经网络算法,将滤波预测状态值与真实轨迹相比存在的误差作为输入,通过模型训练输出轨迹预测理论的滤波误差值,并将长短期记忆神经网络得到的理论误差值补偿扩展卡尔曼滤波算法,得到更加精确的预测效果。最后,将提出的 EKF-LSTM 算法与单一算法 EKF 和 LSTM 针对无人机不同的运动模型,进行预测分析比较,验证算法的可靠性。

3.1 无人机观测方程和状态方程

毫米波雷达常用于处理环境感知、目标追踪、路径规划及自主避障等问题^[52]。在解决轨迹预测问题时,通常需要通过雷达获取初步的位置,再进行后续的预测工作。针对无人机轨迹预测问题,为了便于后续运用扩展卡尔曼滤波器进行预测,需要对无人机观测方程和状态方程进行确定。

毫米波雷达能够对目标进行 360° 探索,毫米波雷达探测时主要通过目标到雷达距离 r ,目标与雷达间方位角 φ 和极角 θ 三个参数来确定目标相对于雷达具体位置。为便于扩展卡尔曼滤波将毫米波雷达探测数据用来估计无人机运动位置参数 (x, y, z) ,需要将雷达探测常用球坐标系与无人机飞行常用三维直角坐标系进行转换。以获得扩展卡尔曼滤波可识别的观测方程。具体的转换图和观测方程如下。




图 3-1 坐标转换

$$Z(k) = \begin{bmatrix} r \\ \theta \\ \varphi \end{bmatrix} = \begin{bmatrix} \sqrt{x_k^2 + y_k^2 + z_k^2} \\ a \cos\left(\frac{z_k}{r}\right) \\ a \tan\left(\frac{y_k}{x_k}\right) \end{bmatrix} + V \quad (3.1)$$

式中, $Z(k)$ 表示 k 时刻雷达探测下无人机的观测方程矩阵; r 为目标无人机与雷达之间的距离; θ 为无人机与雷达之间形成的极角; φ 为无人机与雷达形成的方位角; (x_k, y_k, z_k) 为无人机在三维直角坐标系下的具体位置; V 为雷达观测噪声矩阵, 具体噪声大小跟所预测的运动模型有关。

因毫米波雷达探测具有实时性, 探测间隔较短, 在不确定无人机运动状态的情况下进行轨迹预测时, 通常将两时刻间的运动近似为匀速运动, 如下所示:

$$x_t = x_{t-1} + (\Delta t)v_{t-1} \quad (3.2)$$

式中, x_t 为目标位置信息; Δt 为间隔时间; v_{t-1} 为前一时刻的速度信息。

在实际的雷达探测中, 设置探测间隔为 T , 雷达对目标无人机探测示意图如图 3.2 所示, 在加入了噪音干扰后, 通过数据处理, 得到无人机状态转移矩阵如下:




图 3-2 雷达探测目标无人机状态信息

$$X(k) = \begin{bmatrix} x(k) \\ y(k) \\ z(k) \\ v_x(k) \\ v_y(k) \\ v_z(k) \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & t & 0 & 0 \\ 0 & 1 & 0 & 0 & t & 0 \\ 0 & 0 & 1 & 0 & 0 & t \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x(k-1) \\ y(k-1) \\ z(k-1) \\ v_x(k-1) \\ v_y(k-1) \\ v_z(k-1) \end{bmatrix} + W \quad (3.3)$$

式中, $x(k)$ 、 $y(k)$ 、 $z(k)$ 为当前时刻无人机在直角坐标系中的位置; $v_x(k)$ 、 $v_y(k)$ 、 $v_z(k)$ 为当前时刻无人机在坐标系中对应的速度; $x(k-1)$ 、 $y(k-1)$ 、 $z(k-1)$

为前一时刻无人机在坐标系中的位置； $v_x(k-1)$ 、 $v_y(k-1)$ 、 $v_z(k-1)$ 为前一时刻无人机在坐标系中的速度； $X(k)$ 为系统的状态方程； W 为过程噪声。

综上所述，毫米波雷达针对无人机运动初步的状态转移矩阵和观测矩阵如式(3.1)、式(3.3)所示，但在实际进行预测过程中，因无人机不会只做匀速运动，运动状态会发生改变，为保证预测的准确性，状态转移矩阵会根据不同的运动模型进行改变，状态转移矩阵及噪声具体表达形式在本章 3.2 节中进行详细叙述。

3.2 无人机运动模型

当前针对无人机目标追踪问题，所运用的目标追踪算法都是基于运动模型进行状态估计的。无人机在飞行过程中，用雷达监测器能够获取其速度、位置、角速度以及加速度等信息，其中加速度作为无人机飞行重要参数，其取值不同决定了不同的运动状态。加速度主要包括了切向加速度 $a_t(t)$ 和法向加速度 $a_n(t)$ 。在物体运动过程中，切向加速度影响速度大小的变化，法向加速度影响速度方向的变化^[53]。在本章进行无人机轨迹预测部分，主要针对无人机常见的三种运动模型^[16]：匀速运动模型（CV），匀加速运动模型（CA）、匀转速运动模型（CT）进行状态转移矩阵分析，三种状态对应的加速度取值如下：

$$\begin{aligned} a_n(t)=0; a_t(t)=0 & \quad \text{匀速运动;} \\ a_n(t)=0; a_t(t) \neq 0 & \quad \text{匀加速运动;} \\ a_n(t) \neq 0; a_t(t)=0 & \quad \text{匀转速运动。} \end{aligned}$$

3.2.1 匀速运动模型

当无人机 $a_t(t)$ 和 $a_n(t)$ 都为零时，此时做匀速运动，加速度为零，状态量主要为位置速度信息。假设在第 k 个采样周期下无人机做匀速运动将状态模型定义为：

$$X_k = [x, y, z, \dot{x}, \dot{y}, \dot{z}]^T \quad (3.4)$$

式中， x, y, z 表示 k 时刻无人机位置信息； $\dot{x}, \dot{y}, \dot{z}$ 表示 k 时刻无人机速度信息。

在受到过程高斯白噪声的影响下，设定采样周期 T ，可以得到无人机 CV 模型下的离散的状态方程表达式和展开式^[54]：

$$X_{k+1} = F_{cvk} X_k + \Gamma W_k \quad (3.5)$$

$$X_{k+1} = \begin{bmatrix} 1 & 0 & 0 & T & 0 & 0 \\ 0 & 1 & 0 & 0 & T & 0 \\ 0 & 0 & 1 & 0 & 0 & T \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} X_k + \begin{bmatrix} \frac{T^2}{2} & 0 & 0 \\ 0 & \frac{T^2}{2} & 0 \\ 0 & 0 & \frac{T^2}{2} \\ T & 0 & 0 \\ 0 & T & 0 \\ 0 & 0 & T \end{bmatrix} W_k \quad (3.6)$$

式中, X_k 为状态矩阵; F_{cak} 为匀速运动下状态转移矩阵; Γ 为噪声驱动矩阵; W_k 为均值为零, 方差为 σ_w^2 的白噪声。

3.2.2 匀加速运动模型

当无人机的 $a_t(t)$ 不为零, $a_n(t)$ 为零时, 无人机做匀加速运动, 无人机的速度大小发生线性改变, 无人机方向信息不受影响。此时无人机的状态量包含位置、速度、加速度三个参数。假定在 k 时刻无人机做匀加速运动, 无人机状态模型可定义为:

$$X_k = [x, y, z, \dot{x}, \dot{y}, \dot{z}, \ddot{x}, \ddot{y}, \ddot{z}]^T \quad (3.7)$$

式中, x, y, z 表示 k 时刻下无人机位置信息; $\dot{x}, \dot{y}, \dot{z}$ 表示 k 时刻下无人机速度信息; $\ddot{x}, \ddot{y}, \ddot{z}$ 表示 k 时刻下无人机加速度信息。

当无人机做匀加速运动时, 设定采样周期 T , 在受到离散高斯白噪声影响下, 可以得到无人机 CA 模型下的离散的状态方程表达式和展开式^[54]:

$$X_{k+1} = F_{cak} X_k + \Gamma W_k \quad (3.8)$$

$$X_{k+1} = \begin{bmatrix} I_3 & I_3 \cdot T & I_3 \cdot \frac{T^2}{2} \\ 0_3 & I_3 & I_3 \cdot T \\ 0_3 & 0_3 & I_3 \end{bmatrix} X_k + \begin{bmatrix} I_3 \cdot \frac{T^2}{2} \\ I_3 \cdot T \\ I_3 \end{bmatrix} W_k \quad (3.9)$$

式中, I_3 为三阶单位矩阵; 0_3 为 3 阶零矩阵; X_k 为状态矩阵; F_{cak} 为匀加速运动下状态转移矩阵; Γ 为噪声驱动矩阵; W_k 为均值为零, 方差为 σ_w^2 的白噪声。

3.2.3 匀转速运动模型

当无人机的 $a_t(t)$ 为零, $a_n(t)$ 不为零时, 无人机做匀转速运动, 无人机的速率不发生改变, 无人机的运动方向发生改变。在匀转速运动过程中, 保证各方向上角速度大小保持不变, 则转弯带来的加速度变化为 $a = \omega \times v$ 。此时无人机的状态量包含位置、速度、角速度三个参数。假设无人机在 k 时刻做匀转速运动, 得到无人机状态转移模型为:

$$X_k = [x, y, z, \dot{x}, \dot{y}, \dot{z}, \omega_x, \omega_y, \omega_z]^T \quad (3.10)$$

状态转移矩阵的一阶导函数如下：

$$\begin{aligned} \dot{X}(t) &= \begin{bmatrix} 0_3 & I_3 & 0_3 \\ 0_3 & \Omega & 0_3 \\ 0_3 & 0_3 & 0_3 \end{bmatrix} X(t) + \begin{bmatrix} 0_3 \\ 0_3 \\ I_3 \end{bmatrix} W(t) \\ \Omega(\omega) &= \begin{bmatrix} 0 & -\omega_z & \omega_y \\ \omega_z & 0 & -\omega_x \\ -\omega_y & \omega_x & 0 \end{bmatrix} \end{aligned} \quad (3.11)$$

式中， x, y, z 表示 k 时刻无人机位置信息； $\dot{x}, \dot{y}, \dot{z}$ 表示 k 时刻无人机速度信息； $\omega_x, \omega_y, \omega_z$ 表示 k 时刻无人机角速度信息； $X(t)$ 为状态矩阵； $W(t)$ 为噪声矩阵。

相比于匀速运动和匀加速运动，状态转移矩阵均为线性模型，匀转速运动由于存在角速度对加速度的牵连加速度项，因而状态转移矩阵为非线性模型，模型复杂程度更高。

当无人机做匀转速运动时，设定采样周期 T ，在受到离散高斯白噪声影响下，可以得到无人机 CT 模型下的离散的状态方程表达式和展开式：

$$X_{k+1} = F_{ctk} X_k + \Gamma W_k \quad (3.12)$$

其中：

$$\begin{aligned} F_{ct} &= \begin{bmatrix} I_3 & B & 0_3 \\ 0_3 & I_3 + A & 0_3 \\ 0_3 & 0_3 & I_3 \end{bmatrix}, \Gamma = \begin{bmatrix} 0_3 \\ 0_3 \\ I_3 \end{bmatrix} \\ A &= \begin{bmatrix} c_1 d_1 & -c_2 \omega_z - c_1 \omega_x \omega_y & c_2 \omega_y - c_1 \omega_x \omega_z \\ c_2 \omega_z - c_1 \omega_x \omega_y & c_1 d_2 & -c_2 \omega_x - c_1 \omega_y \omega_z \\ -c_2 \omega_y - c_1 \omega_x \omega_z & c_2 \omega_x - c_1 \omega_y \omega_z & c_1 d_3 \end{bmatrix} \\ B &= \begin{bmatrix} c_3 d_1 & c_1 \omega_z - c_3 \omega_x \omega_y & -c_1 \omega_y - c_3 \omega_x \omega_z \\ -c_1 \omega_z - c_3 \omega_x \omega_y & c_3 d_2 & c_1 \omega_x - c_3 \omega_y \omega_z \\ c_1 \omega_y - c_3 \omega_x \omega_z & -c_1 \omega_x - c_3 \omega_y \omega_z & c_3 d_3 \end{bmatrix} \end{aligned} \quad (3.14)$$

根据文献^[55]推导出参数 c 、 d 值如下：

$$\begin{aligned} c_1 &= \frac{\cos \Omega T - 1}{\Omega^2}, c_2 = \frac{\sin \Omega T}{\Omega}, c_3 = \frac{1}{\Omega^2} \left(\frac{\sin \Omega T}{\Omega} - T \right) \\ d_1 &= \omega_y^2 + \omega_z^2, d_2 = \omega_x^2 + \omega_z^2, d_3 = \omega_x^2 + \omega_y^2 \end{aligned} \quad (3.15)$$

其中， I_3 为三阶单位矩阵； 0_3 为 3 阶零矩阵； X_k 为状态矩阵； F_{ctk} 为匀转速运动下状态转移矩阵； Γ 为噪声驱动矩阵； W_k 为均值为零，方差为 σ_w^2 的白噪声。因匀转速运动状态转移矩阵非线性程度较高，在后续进行轨迹预测时需要对象速

度进行准确估计，才能更好实现轨迹预测效果。

3.3 扩展卡尔曼滤波

传统的卡尔曼滤波算法作为一种模型化预测算法，通过以获得的模型和噪声特征，借助测量数据实现对系统状态量的估计，达到预测的效果。对于常规的线性系统，采用 KF 算法能够有效实现预测。但在无人机轨迹预测中，为了准确估计其运动状态，通常使用自动识别、激光雷达进行观测，获取的观测数据存在非线性因素，用传统 KF 算法会导致滤波结果发散，无法实现准确预测。对于非线性系统滤波问题，扩展卡尔曼滤波 (EKF) 算法是目前应用最广泛的算法。EKF 算法是在传统 KF 算法基础上衍生出来的算法。其算法的核心思想是，将非线性系统函数围绕滤波值进行泰勒级数展开，保留一阶项，省略二阶及以上项，得到一个近似的线性化模型。再根据 KF 算法的原理完成对目标的滤波估计^[56]。

假设非线性系统的表达式如下所示：

$$\begin{cases} X(k+1) = f[k, X(k)] + W(k) \\ Z(k) = h[k, X(k)] + V(k) \end{cases} \quad (3.16)$$

式中， $X(k+1)$ 表示状态向量； $Z(k)$ 表示观测向量； $f[k, X(k)]$ 、 $h[k, X(k)]$ 分别表示非线性系统中的状态函数和观测函数； $W(k)$ 和 $V(k)$ 为相互独立的高斯白噪声，其中 $W(k)$ 表示过程噪声， $V(k)$ 表示观测噪声。

将非线性系统函数 $f[k, X(k)]$ 和 $h[k, X(k)]$ 围绕滤波值 $\hat{X}(k)$ 进行一阶泰勒级数展开：

$$\begin{cases} X(k+1) = f[k, \hat{X}(k)] + \frac{\partial f}{\partial \hat{X}(k)} [X(k) - \hat{X}(k)] + W(k) + \gamma(k) \\ Z(k) = h[k, X(k|k-1)] + \frac{\partial h}{\partial \hat{X}(k)} \Big|_{\hat{X}(k,k-1)} [X(k) - \hat{X}(k|k-1)] + V(k) + y(k) \end{cases} \quad (3.17)$$

式中， $\frac{\partial f}{\partial \hat{X}(k)}$ 和 $\frac{\partial h}{\partial \hat{X}(k)}$ 为雅可比矩阵； $\gamma(k)$ 和 $y(k)$ 为状态方程和观测方程对

应的泰勒余项。

假设状态向量为 n 维，即 $X = [x_1 \ x_2 \ \cdots \ x_n]$ ，雅可比矩阵计算如下所示：

$$\begin{aligned}
\Phi(k+1) &= \frac{\partial f}{\partial \hat{X}(k)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix} \\
H(k+1) &= \frac{\partial h}{\partial \hat{X}(k)} = \begin{bmatrix} \frac{\partial h_1}{\partial x_1} & \frac{\partial h_1}{\partial x_2} & \dots & \frac{\partial h_1}{\partial x_n} \\ \frac{\partial h_2}{\partial x_1} & \frac{\partial h_2}{\partial x_2} & \dots & \frac{\partial h_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial h_n}{\partial x_1} & \frac{\partial h_n}{\partial x_2} & \dots & \frac{\partial h_n}{\partial x_n} \end{bmatrix}
\end{aligned} \tag{3.18}$$

根据上述步骤，可以将非线性系统中的状态方程和观测方程近似转化为线性表达式。简化模型后，运用扩展卡尔曼滤波预测-更新步骤进行迭代运算即可进行对目标的预测分析^[57]。接下来将具体阐述 EKF 算法针对无人机目标追踪问题进行的具体迭代过程。

步骤一：初始化滤波参数

分别对无人机飞行的状态向量 $X(0)$ ，误差协方差矩阵 $P(0)$ ，过程噪声矩阵 Q 和观测噪声 R 进行初始化。

步骤二：滤波器预测部分

分析无人机的运动状态，确定其运动模型，参照 3.2 小节方法，列出对应运动状态下的状态方程，并对状态向量进行预测

$$\hat{X}(k|k+1) = f(\hat{X}(k|k)) \tag{3.19}$$

根据运动模型确定状态方程对应的雅可比矩阵 $\Phi(k+1)$ ，计算协方差预测值。

$$P(k+1|k) = \Phi(k+1)P(k|k)\Phi^T(k+1) + Q(k+1) \tag{3.20}$$

步骤三：滤波器更新部分

根据无人机观测方程，参照 3.1 小节雷达观测原理，列出无人机观测方程 $Z(k+1)$ ，求出观测方程对应的雅可比矩阵 $H(k+1)$ ，并更新卡尔曼滤波增益

$$K(k+1) = P(k+1|k)H^T(k+1)[H(k+1)P(k+1|k)H^T(k+1) + R]^{-1} \tag{3.21}$$

更新状态向量值

$$\hat{X}(k+1|k+1) = \hat{X}(k+1|k) + K(k+1)[Z(k+1) - h(\hat{X}(k+1|k))] \tag{3.22}$$

更新协方差矩阵

$$P(k+1) = [I - K(k+1)H(k+1)]P(k+1|k) \tag{3.23}$$

3.4 循环神经网络

神经网络算法^[58]最早是由心理学家 W.McCulloch 和数学逻辑家 W.Pitts 提出,通过研究分析人的神经元反射活动,将其原理移植在分析和计算领域,提出了基于神经元的数学模型。在神经网络基础模型中主要包括用于接收外部信息的输入层,用于处理数据并提取特征的隐含层,以及通过接收隐含层信息生成最终结果的输出层。在基础神经网络中,由于隐含层数量较少,且每一层的神经元只与相邻层的神经元通过权值进行连接,其结构简单只能用于处理简单的分类回归问题。对于本章研究无人机轨迹预测这一动态过程问题,需要采用基于机器学习的深度神经网络。

循环神经网络^[59]是一种用于时序性预测的深度学习神经网络,在轨迹预测中,能够通过获取目标的位置状态相关参数,作为时间序列的信息,通过网络进行训练学习,最终输出结果,达到预测的目的。其中 RNN 神经网络算法和 LSTM 神经网络算法是目前运用最广泛的循环神经网络算法。

3.4.1 RNN 神经网络

RNN 相比传统的神经网络模型,在隐含层处引入了循环连接,可以将运算的数据进行保存,运用到后续的分析计算中,实现了时间记忆功能。在 RNN 中,所有的神经元都采用链式规则进行连接^[60],通过这种连接方式能够增强与前一时刻之间的联系,RNN 的单元结构图如图 3.3 所示。




图 3-3 RNN 单元结构图

RNN 的随时间序列展开图,如图 3-4 所示。




图 3-4 RNN 时序展开图

上图， x_{t-1} 、 x_t 、 x_{t+1} 分别表示 RNN 网络前一时刻、当前时刻、下一时刻的输入， s_{t-1} 、 s_t 、 s_{t+1} 分别表示 RNN 隐含层前一时刻、当前时刻、下一时刻的状态值， o_{t-1} 、 o_t 、 o_{t+1} 分别表示 RNN 输出层前一时刻、当前时刻、下一时刻的输出值。U 表示输入层权重矩阵，V 表示输出层的权重矩阵，W 表示隐藏层权重矩阵。在 RNN 计算时每一步使用参数 U、V、W 都是共享的，RNN 算法具体计算过程如下所示：

$$s_t = f^1(W \cdot s_{t-1} + Ux_t + b_s) \quad (3.24)$$

$$o_t = f^2(V \cdot s_t + b_o) \quad (3.25)$$

式中， f^1 、 f^2 表示激活函数， b_s 、 b_o 分别表示隐含层和输出层的阈值。

3.4.2 长短期记忆神经网络

在 RNN 算法中，因为输入层、隐含层、输出层的权重矩阵参数均共享，当随着时间步长增加时，延时间步反向传播（BPTT）运算^[61]会存在对长距离神经元依赖关系减弱，短距离神经元依赖关系增加，从而造成梯度消失和梯度爆炸的问题。为了解决 RNN 算法只能处理短期记忆问题^[62]，LSTM 在 RNN 基础上做出了相应的改进，增加了门控循环，在储存信息中增加了记忆细胞，实现长期记忆的功能。LSTM 的结构如图 3-5 所示。




图 3-5 LSTM 结构图

如图所示, f_t 、 i_t 、 o_t 分别表示遗忘门、输入门、输出门; X_t 表示当前时刻网络输入值; C_t 、 C_{t-1} 分别表示网络当前时刻和上一时刻细胞状态; $\tilde{C}_t$ 表示细胞候选状态; h_t 、 h_{t-1} 分别表示网络当前时刻和上一时刻的输出; 符号 $\times$ 、 $+$ 分别表示向量相乘和向量相加; σ 、 $\tanh$ 分别表示激活函数 sigmoid 和激活函数 tanh。

LSTM 算法主要包含遗忘门、输入门、细胞状态更新、输出门四个部分。遗忘门作用是控制上一时刻细胞状态对当前影响, 通过网络读取上一时刻输出结果 h_{t-1} 和当前时刻时序序列的输入 X_t , 通过 sigmoid 函数进行处理计算公式如下:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (3.26)$$

式中, W_f 、 b_f 分别表示遗忘门的权值和阈值; 遗忘门中向量 f_t 的取值区间为 $[0, 1]$, 其中 1 表示完全保留上一时刻输出结果信息, 0 表示完全遗忘上一时刻的输出结果。

输入门的主要作用是控制新信息选择性进入到细胞状态中。在输入门中主要包括了 sigmoid 层和 tanh 层。其中 sigmoid 层决定输入的哪些信息将被更新, tanh 层通过计算确定细胞候选状态值 $\tilde{C}_t$ 。具体的计算公式如下:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (3.27)$$

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3.28)$$

式中, W_i 、 b_i 分别表示输入门的权值和阈值; W_c 、 b_c 分别表示细胞状态的权值和阈值, 其中 i_t 的区间为 $[0, 1]$ 。

细胞状态是 LSTM 网络实现长短期记忆的核心组成成分, 用于储存和传递当前时序序列的信息。细胞状态更新过程中将上一时刻的细胞状态值 C_{t-1} 与遗忘门中向量值 f_t 相乘加上细胞候选状态值 $\tilde{C}_t$ 与输入门向量值 i_t 相乘得到更新的状态值, 具体公式如下:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (3.29)$$

输出门的作用是输出预测的最终值, 根据更新的细胞状态 C_t 进行选择输出。具体的计算公式如下:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (3.30)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (3.31)$$

式中, W_o 、 b_o 分别表示输出门的权值和阈值。

3.5 EKF-LSTM 算法

3.5.1 算法结构

EKF 算法和 LSTM 算法均能实现对目标的轨迹预测, 其中 EKF 算法预测速度快但处理较复杂运动模型时预测精度较差, LSTM 算法解决轨迹预测问题时预测精度高, 但预测速度相对较慢, 实时性较差。为了结合两种算法的优势, 更好

的实现无人机轨迹预测，本文提出 EKF-LSTM 结合算法，具体步骤如下：

(1) 通过运用毫米波雷达对无人机进行实时观测，获取无人机的状态信息，确定无人机的运动模型，并列出状态转移矩阵表达式。

(2) 得到毫米波雷达的观测方程和状态转移方程后，运用 EKF 算法对无人机进行初步的预测。

(3) 计算滤波误差，将滤波误差和前两时刻无人机的状态信息作为 LSTM 神经网络的输入，通过 LSTM 算法输出理论的滤波误差值。

(4) 通过将 LSTM 算法输出理论误差值补偿 EKF 算法达到最终的预测效果。




图 3-6 EKF-LSTM 算法结构图

3.5.2 LSTM 神经网络在 EKF-LSTM 算法中的应用

在运用 EKF-LSTM 算法进行轨迹预测时，LSTM 神经网络的数据集为滤波误差和无人机状态参数信息。在进行网络训练前需要对数据进行预处理。本文通过采用离差标准化（min-max normalization）方法^[63]，对数据进行归一化处理。将所得信息经过处理后设置在值域为[0,1]区间中，转化为 LSTM 可识别的时序序列。具体的转化过程如下：

$$\tilde{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3.32)$$

式中， $\tilde{x}$ 表示数据归一化处理后的结果值； x 表示输入的原始数据； $x_{\max}$ 为数据集中的最大值； $x_{\min}$ 为数据集中的最小值。

通过数据预处理后，对 LSTM 神经网络进行参数设计，重要参数设计如下：

(1) 输入层步数

在神经网络中，网络训练速度受到输入层步数的影响。对于无人机轨迹预测问题，考虑到需对无人机进行实时预测，神经网络所参考的点数不宜太多^[64]。本文选取无人机前两时刻的状态参数以及对应的滤波误差作为网络的输入层步数，输入层步数为 3。

(2) 优化器

在神经网络进行模型训练时，使用优化器可以调整网络参数，优化网络模型性能，常用的优化器有梯度下降（SGD）优化器、动量法优化器、adam 优化器^[65]等。为了在无人机轨迹预测中能够对数据进行快速收敛，具有较好泛化能力本文 LSTM 神经网络选用 adam 优化器。

(3) 损失函数

为了评估模型的性能，会根据处理不同的问题，设置相对应的损失函数。对于分类问题通常选用交叉熵损失函数（Binary Cross-Entropy Loss），对于回归类问题常用均方误差（MSE）、均方根误差（RMSE）函数。对于无人机轨迹预测需要预测连续值的情况，本文损失函数采用 RMSE，具体公式如下：

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - p_i)^2} \quad (3.33)$$

式中， y_i 为真实值； p_i 为神经网络预测值。

在参数设计后，通过训练 LSTM 网络，将所得数据进行反归一化处理，得到当前时刻 EKF 算法预测无人机状态参数的理论误差值，将扩展卡尔曼滤波器的实际预测结果加上 LSTM 神经网络预测的理论误差值，实现对无人机更准确的轨迹预测效果。

3.6 算法仿真实验与对比分析

3.6.1 仿真方案和数据参数设置

为验证本文所提出的 EKF-LSTM 算法在轨迹预测中的效果，针对无人机三种常见的运动模型（CV：匀速运动、CA：匀加速运动、CT：匀转速运动）生成相应的轨迹，进行轨迹预测。在设置同等噪音干扰条件下，将 EKF-LSTM 算法与 EKF 算法和 LSTM 算法进行追踪性能的比较。

对于三种运动模型的轨迹设计，采用下式^[66]进行设计生成：

$$X_k = FX_{k-1} + W \quad (3.34)$$

式中， F 表示三种运动模型下的状态转移矩阵，参考本章 3.2 小节生成； X_k 为无人机飞行环境下的状态向量，针对不同运动模型设置相应的状态向量参数； W 为噪声转移矩阵。

在轨迹预测中,本文设置毫米波雷达探测间隔为 0.05s,探测总时长为 10s。LSTM 神经网络前 40%用于模型训练,后 60%用于目标测试,三种运动模型对应的实验测试数均为 120。目标观测点设置为原点,为简化计算,无人机在三种运动模型下均从原点出发,在 CV 模型中设定无人机的速度为 $[5\text{m/s}, 3\text{m/s}, 5\text{m/s}]$,在 CA 模型中设定无人机的速度为 $[1\text{m/s}, 2\text{m/s}, 4\text{m/s}]$,加速度为 $[1\text{m/s}^2, 0.5\text{m/s}^2, 1.5\text{m/s}^2]$ 。CT 模型中设定无人机的速度为 $[10\text{m/s}, 10\text{m/s}, 10\text{m/s}]$,角速度为 $[0.1\text{rad/s}, 0.2\text{rad/s}, 0.3\text{rad/s}]$ 。在无噪声干扰的情况下,三种运动模型在测试集下的真实轨迹如图 3-7 所示。




图 3-7 三种运动模型下测试集的真实轨迹

根据生成的运动轨迹,在轨迹预测对比实验中,本文采用仿真环境为:硬件设备采用 IntelXeon CPUE3-1225v6@3.30GHz,安装内存为 12GB,操作系统为 Windows 10 家庭版 64 位操作系统,运行平台为 Matlab 2022b,模型训练通过 GPU 处理计算。其中 LSTM 神经网络的参数参考本节 3.5.2 设计如下表 3.1 所示。

表 3.1 参数设置

参数	实验设置	参数	实验设置
学习率	0.01	迭代次数	60
优化器	Adam	损失函数	RMSE
激活函数	tanh/sigmoid	系统噪声方差	0.35
观测噪声方差	0.05	LSTM 输入层步数	3

3.6.2 仿真对比分析

由于无人机轨迹预测对跟踪的实时性要求较高,在进行仿真实验前,将 EKF-LSTM 算法与 EKF 算法和 LSTM 算法的运行单步时长与雷达检测间隔时长进行对比验证是否满足实时预测要求。对比结果如图 3-8 所示。




图 3-8 各算法单步时长对比图

由图 3-8 看出,本文提出的 EKF-LSTM 算法单步运行时长约为 0.03s 左右,与运用模型化预测的 EKF 算法相比,由于为了提高预测精度在传统的 EKF 算法基础上,针对滤波误差运用 LSTM 算法进行运算,并补偿滤波值,单步运行时长更长。但与传统 LSTM 算法在无人机轨迹预测时需要参考整个运动历史轨迹,本文所用的 EKF-LSTM 算法中神经网络数据集为滤波误差信息,减少了神经网络的输入量,单步运行时长更短。考虑到三种算法的单步时长均小于雷达检测间隔 0.05s,所以都能够满足实时预测需求。

验证算法满足实时性后,进行仿真实验在三种运动模型下,EKF-LSTM 算法与 EKF 算法和 LSTM 算法的预测轨迹图,无人机状态参数误差图如下。

(1) 匀速运动模型

在 CV 模型中,无人机切向和法向加速度为 0,无人机的状态参数为 $X=[x,y,z,v_x,v_y,v_z]$,在速度不变的情况下通过分析轨迹图和距离误差图可以看出,EKF 算法的误差波动性较大,所提出 EKF-LSTM 算法,距离误差最小,精度提升较明显。




图 3-9 匀速运动模型轨迹图




图 3-10 匀速运动模型距离误差图

(2) 匀加速运动模型

在 CA 模型中, 无人机飞行具有切向加速度, 无人机的状态参数为 $X = [x, y, z, \dot{x}, \dot{y}, \dot{z}, \ddot{x}, \ddot{y}, \ddot{z}]$, 其中速度和位置都会随时间发生改变, 通过分析比较轨迹图, 距离误差图和速度误差图, 看出所提出的 EKF-LSTM 算法的跟踪误差最小, 在相同噪音的干扰下, 追踪更加稳定。




图 3-11 匀加速运动模型轨迹图




图 3-12 匀加速运动模型距离误差图




图 3-13 匀加速运动模型速度误差图

(3) 匀转速运动模型

在 CT 模型中, 无人机飞行具有法向加速度, 无人机的状态参数为 $X=[x, y, z, \dot{x}, \dot{y}, \dot{z}, \omega_x, \omega_y, \omega_z]$, 因状态转移矩阵为非线性方程, 在轨迹预测时三种

算法的拟合程度相对较差,但通过分析轨迹图,距离误差图和速度误差图也得出所提出的 EKF-LSTM 算法在追踪精度上相比单一算法有所提升。




图 3-14 匀转速运动模型轨迹图




图 3-15 匀转速运动模型距离误差图




图 3-16 匀转速运动模型速度误差图

算法在三种运动模型下的预测精度对比如表 3.2 所示。从表中可以看出,随

运动模型复杂程度增加, 无人机轨迹预测的距离误差和速度误差相应增大。在三种算法中 EKF-LSTM 算法追踪精度最高, 在三个模型的预测中其误差平均值均在 1m 以内。综上所述, 本文提出的 EKF-LSTM 算法相比单一算法 EKF 算法和 LSTM 算法能更好地处理无人机轨迹预测的问题, 符合轨迹欺骗前期对目标无人机进行轨迹预测的追踪精度要求, 但该算法还存在一点不足, 因算法是在 EKF 算法基础上, 运用 LSTM 算法进行误差补偿, 在预测的时效性上相比模型化预测略差, 后续可以通过改进算法结合方式, 调整优化神经网络参数, 更好地实现对目标的追踪效果。

表 3.2 算法在三种模型下的预测精度对比

模型	算法	距离平均误差	距离最大误差	速度平均误差	速度最大误差
CV 模型	EKF	0.830m	2.477m	-	-
	LSTM	0.277m	0.586m	-	-
	EKF-LSTM	0.083m	0.202m	-	-
CA 模型	EKF	1.673m	4.557m	1.248m/s	3.582m/s
	LSTM	0.959m	1.906m	0.154m/s	0.278m/s
	EKF-LSTM	0.293m	0.639m	0.067m/s	0.138m/s
CT 模型	EKF	1.997m	4.107m	1.113m/s	3.953m/s
	LSTM	1.476m	3.503m	0.352m/s	0.749m/s
	EKF-LSTM	0.583m	1.186m	0.117m/s	0.260m/s

3.7 本章小结

本章主要研究无人机轨迹欺骗下的轨迹预测问题, 首先针对无人机常见的运动模型进行分析, 确定了用于模型化预测所需要的状态方程和观测方程。然后分别介绍了用于模型化预测的 EKF 算法和应用深度学习神经网络的 LSTM 算法的具体流程, 通过分析算法优缺点, 提出了 EKF-LSTM 融合算法的具体流程方案和神经网络的参数设置。最后, 设计仿真实验, 针对匀速、匀加速、匀转速三种常见运动模型生成相应的路径进行轨迹预测算法对比, 得出所提出的 EKF-LSTM 算法相比 EKF 算法和 LSTM 算法追踪精度更高, 能够更好地解决无人机轨迹预测问题。